Carga inicial datos: Physionet 2012 UCI data mortality

Ricardo Alberich, Irene Garcia

Contents

1	Introducción: Physionet 2012 UCI data mortality		
	1.1	Enlaces de interés	1
2	Inge	Ingesta de datos	
	2.1	Modelo de datos	1
	2.2	Carga set_a	2
	2.3	En resumen tenemos	3
	2.4	Unificar: series, perfiles y scores	4

1 Introducción: Physionet 2012 UCI data mortality

En el concurso del congreso "Computers in Cardiology" (ahora "Computing in Cardiology") del año 2012 propuso un caso de estudio como reto: Predicción de la tasa de mortalidad de los pacientes de una UCI

- https://physionet.org/content/challenge-2018/
 https://physionet.org/content/challenge-2019/

1.1 Enlaces de interés

Resto de años mas recientes

HR: Heart Rate bpm beats per minut

GCS: Glasgow Comma Score (scale 3-15)

RespRate: Respiration rate (bpm) breaths for one minute

2 Ingesta de datos

2.1 Modelo de datos

```
# Cargamos los datos
path = "data_basic_physionet/set-a/"# path training
# Creamos un vector con los nombres de los archivos
lista_pacientes_set_a = dir(path) # lista ficheros pacientes
# Printamos número de archivos que leemos
length(lista_pacientes_set_a) # número pacientes en training
```

```
# Mostramos como ejemplo el nombre del documento 1 de los datos
lista_pacientes_set_a[1]
## [1] "132539.txt"
data_paciente_132539=read_csv("data_basic_physionet/set-a/132539.txt", col_types =cols(Time=col_time(fo
Value=col_double()))
str(data_paciente_132539)
glimpse(data_paciente_132539)
class(data_paciente_132539)
head(data_paciente_132539,30)
2.2
     Carga set a
# lista path's a cada ficjero de paciente
list_files = paste0(path,lista_pacientes_set_a)
# Función leer paciente
# Leemos el tiempo como carácter y después haremos un ajuste que nos lo simplifique todo a minutos.
leer_paciente = function(file){read_csv(file, col_types = cols(Time = col_character(),
                                                               Parameter = col_character(),
                                                               Value = col_double())) %>%
                              separate(Time,into = c("H","M"),sep = ":") %>%
                              mutate(Time Minutes = as.numeric(H)*60+as.numeric(M)) %>%
                              select(Time_Minutes,Parameter,Value)}
```

```
# Separamos las horas de los minutos de la columna Time para acto seguido poner una sola columna
# llamada Time_min sólo con los minutos en que se tomaron los datos.
#leer_paciente(list_files[1])
raw_data = lapply(list_files,leer_paciente) # lista de los datos por paciente
#extraer perfiles "RecordID" "Age"
                                        "Gender"
                                                    "Heiaht"
                                                               "Weiaht"
                                                                          "ICUType"
perfil = function(data_paciente){
            data_paciente %>%
            filter(Parameter %in% c("RecordID", "Age", "Gender", "Height", "ICUType", "Weight")) %>%
            select(-Time_Minutes) %>%
            distinct(Parameter,.keep_all = TRUE) %>%
            spread(Parameter, Value) }
## ejemplo
#perfil(data_paciente_132539)
## Guardo todos los datos del perfil de cada paciente
perfiles = lapply(raw_data,perfil) %>%
            bind rows() %>%
            select(RecordID, Age, Gender, Height, Weight, ICUType)
glimpse(perfiles)
## Observations: 4,000
## Variables: 6
## $ RecordID <dbl> 132539, 132540, 132541, 132543, 132545, 132547, 13254...
              <dbl> 54, 76, 44, 68, 88, 64, 68, 78, 64, 74, 64, 71, 66, 8...
## $ Age
```

```
## $ Gender
              <dbl> 0, 1, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 0, 1, 1, 1, 1, 1, ...
              <dbl> -1.0, 175.3, -1.0, 180.3, -1.0, 180.3, 162.6, 162.6, ...
## $ Height
## $ Weight
              <dbl> -1.0, 76.0, 56.7, 84.6, -1.0, 114.0, 87.0, 48.4, 60.7...
## $ ICUType <dbl> 4, 2, 3, 3, 3, 1, 3, 3, 3, 2, 3, 2, 3, 1, 1, 2, 3, 3,...
## Ler series
\#\# se modifica error de time
serie_UCI_parameter <- function(paciente,parameters){ paciente %>%
                                                      arrange(Parameter, Time_Minutes) %>%
                                                      filter(Parameter %in% parameters) %>%
                                                      add_column(RecordID=paciente[1,3]$Value) }
##ejemplo
parameters = c("HR","RespRate","GCS")
serie_paciente1 = serie_UCI_parameter(raw_data[[1]],parameters)
serie_paciente1
## # A tibble: 92 x 4
##
      Time Minutes Parameter Value RecordID
             <dbl> <chr>
                            <dbl>
                                      <dbl>
##
## 1
                7 GCS
                                15
                                     132539
              217 GCS
                                    132539
## 2
                                15
## 3
              457 GCS
                                15
                                     132539
              697 GCS
## 4
                                15
                                     132539
## 5
              937 GCS
                                15
                                     132539
## 6
             1177 GCS
                                     132539
              1417 GCS
## 7
                                15
                                     132539
## 8
              1657 GCS
                                15
                                     132539
## 9
              1897 GCS
                                14
                                     132539
              2137 GCS
                                15
                                     132539
## # ... with 82 more rows
# paso TODOS los parámetros y apilo
parameters=c("Albumin","ALP","ALT","AST","Bilirubin","BUN","Cholesterol","Creatinine","DiasABP","FiO2",
series_parameters = lapply(raw_data,FUN=function(x) serie_UCI_parameter(x,parameters)) %>%
                    bind rows()
glimpse(series_parameters)
## Observations: 1,606,254
## Variables: 4
## $ Time_Minutes <dbl> 637, 1987, 637, 1987, 7, 217, 457, 697, 937, 1177...
                  <chr> "BUN", "BUN", "Creatinine", "Creatinine", "GCS", ...
## $ Parameter
## $ Value
                  <dbl> 13.0, 8.0, 0.8, 0.7, 15.0, 15.0, 15.0, 15.0, 15.0...
## $ RecordID
                  <dbl> 132539, 132539, 132539, 132539, 132539, 132539, 1...
```

2.3 En resumen tenemos

```
#set-a
glimpse(perfiles)
```

```
## Observations: 4,000
## Variables: 6
## $ RecordID <dbl> 132539, 132540, 132541, 132543, 132545, 132547, 13254...
              <dbl> 54, 76, 44, 68, 88, 64, 68, 78, 64, 74, 64, 71, 66, 8...
## $ Age
## $ Gender
              <dbl> 0, 1, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 0, 1, 1, 1, 1, 1, ...
## $ Height <dbl> -1.0, 175.3, -1.0, 180.3, -1.0, 180.3, 162.6, 162.6, ...
## $ Weight
              <dbl> -1.0, 76.0, 56.7, 84.6, -1.0, 114.0, 87.0, 48.4, 60.7...
## $ ICUType <dbl> 4, 2, 3, 3, 3, 1, 3, 3, 3, 2, 3, 2, 3, 1, 1, 2, 3, 3,...
glimpse(series_parameters)
## Observations: 1,606,254
## Variables: 4
## $ Time_Minutes <dbl> 637, 1987, 637, 1987, 7, 217, 457, 697, 937, 1177...
                  <chr> "BUN", "BUN", "Creatinine", "Creatinine", "GCS", ...
## $ Parameter
## $ Value
                  <dbl> 13.0, 8.0, 0.8, 0.7, 15.0, 15.0, 15.0, 15.0, 15.0...
## $ RecordID
                  <dbl> 132539, 132539, 132539, 132539, 132539, 132539, 1...
      Unificar: series, perfiles y scores
Nos faltan los scores clásicos que se utilizan eb las ICU. Estos ewstán el fichero Outcome-a.txt para el set-a
scoresApath = "data_basic_physionet/Outcomes-a.txt"
scoresA = read_csv(scoresApath)
## Parsed with column specification:
## cols(
     RecordID = col_double(),
##
##
     `SAPS-I` = col_double(),
##
    SOFA = col_double(),
##
    Length_of_stay = col_double(),
##
    Survival = col double(),
##
     `In-hospital_death` = col_double()
## )
glimpse(scoresA)
## Observations: 4,000
## Variables: 6
## $ RecordID
                         <dbl> 132539, 132540, 132541, 132543, 132545, 13...
## $ `SAPS-I`
                         <dbl> 6, 16, 21, 7, 17, 14, 14, 19, 11, 14, 15, ...
## $ SOFA
                         <dbl> 1, 8, 11, 1, 2, 11, 4, 8, 0, 6, 2, 7, 2, 7...
## $ Length_of_stay
                         <dbl> 5, 8, 19, 9, 4, 6, 9, 6, 17, 8, 13, 7, 22,...
## $ Survival
                         <dbl> -1, -1, -1, 575, 918, 1637, -1, 5, 38, -1,...
## $ `In-hospital_death` <dbl> 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, ...
```

Scores perfilesA = inner join(perfiles,scoresA, "RecordID")

glimpse(Scores_perfilesA)

```
## Observations: 4,000
## Variables: 11
## $ RecordID
                         <dbl> 132539, 132540, 132541, 132543, 132545, 13...
                         <dbl> 54, 76, 44, 68, 88, 64, 68, 78, 64, 74, 64...
## $ Age
## $ Gender
                         <dbl> 0, 1, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 0, 1, ...
## $ Height
                         <dbl> -1.0, 175.3, -1.0, 180.3, -1.0, 180.3, 162...
## $ Weight
                         <dbl> -1.0, 76.0, 56.7, 84.6, -1.0, 114.0, 87.0,...
                         <dbl> 4, 2, 3, 3, 3, 1, 3, 3, 3, 2, 3, 2, 3, 1, ...
## $ ICUType
## $ `SAPS-I`
                         <dbl> 6, 16, 21, 7, 17, 14, 14, 19, 11, 14, 15, ...
## $ SOFA
                         <dbl> 1, 8, 11, 1, 2, 11, 4, 8, 0, 6, 2, 7, 2, 7...
## $ Length_of_stay
                         <dbl> 5, 8, 19, 9, 4, 6, 9, 6, 17, 8, 13, 7, 22,...
                         <dbl> -1, -1, -1, 575, 918, 1637, -1, 5, 38, -1,...
## $ Survival
## $ `In-hospital_death` <dbl> 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, ...
```

2.4.1 Extracción factores de las series

genero una tabla con resumenes de las variables por paciente: media, desviación típica

```
series_summary =
                  series_parameters %>%
                  group_by(RecordID, Parameter) %>%
                  summarise(count = n(), mean = mean(Value, na.rm = TRUE),
                            sd = sd(Value,na.rm=TRUE)) %>%
                  gather(Stat, Value, count:sd) %>%
                  ungroup() %>%
                  transmute(RecordID, ParameterStat = pasteO(Parameter, "_ ", Stat), Value) %>%
                  spread(ParameterStat, Value)
data_tidy = Scores_perfilesA %>% inner_join(series_summary)
## Joining, by = "RecordID"
Elimino NA
aux=which(is.na(data_tidy$Lactate_count))
length(aux)
## [1] 1814
data_tidy2=data_tidy[-aux,]
view(data_tidy2)
```

Dejamos de considerar por demasiados NA's: - ALP - Bilirubina - Lactate - Resp Rate

```
contar_nas = function(x){
   sum(is.na(x))
}

pocos_nas = function(x){
   for(i in 1:length(x)){
```

```
if(contar_nas(x) >= 1500){
    return(FALSE)
}
else{
    return(TRUE)
}

#data_tidy3 = drop_na(data_tidy)

primera_seleccion = data_tidy %>%
    apply( 2, pocos_nas)

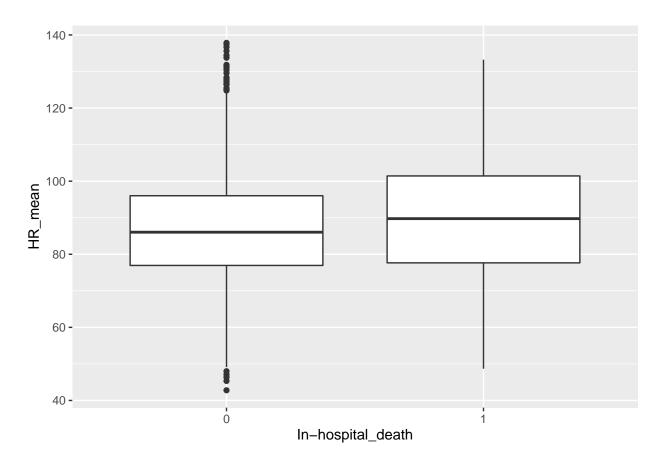
# VARIABLES CON "POCOS NAS" EN LA VARIABLE COUNT
nombres = names(primera_seleccion[primera_seleccion])
nombres
```

```
[1] "RecordID"
                             "Age"
                                                   "Gender"
##
                             "Weight"
##
    [4] "Height"
                                                  "ICUType"
   [7] "SAPS-I"
                             "SOFA"
                                                   "Length_of_stay"
## [10] "Survival"
                             "In-hospital_death"
                                                  "BUN_count"
## [13] "BUN_mean"
                             "BUN sd"
                                                   "Creatinine_count"
## [16] "Creatinine mean"
                             "Creatinine_sd"
                                                  "DiasABP_count"
## [19] "DiasABP mean"
                             "DiasABP sd"
                                                   "FiO2 count"
## [22] "FiO2 mean"
                             "Fi02 sd"
                                                   "GCS count"
## [25] "GCS_mean"
                             "GCS_sd"
                                                   "Glucose_count"
## [28] "Glucose mean"
                             "Glucose_sd"
                                                   "HCO3 count"
## [31] "HCO3_mean"
                             "HCO3_sd"
                                                   "HCT_count"
## [34] "HCT mean"
                             "HCT sd"
                                                   "HR count"
                             "HR_sd"
## [37] "HR_mean"
                                                   "K_count"
## [40] "K_mean"
                             "K sd"
                                                   "MAP_count"
## [43] "MAP_mean"
                             "MAP_sd"
                                                   "MechVent_count"
## [46] "MechVent_mean"
                                                   "Mg_count"
                             "MechVent_sd"
## [49] "Mg_mean"
                             "Mg_sd"
                                                   "Na_count"
## [52] "Na_mean"
                             "Na_sd"
                                                   "NIDiasABP_count"
                                                   "NIMAP_count"
## [55] "NIDiasABP_mean"
                             "NIDiasABP_sd"
## [58] "NIMAP_mean"
                             "NIMAP_sd"
                                                   "NISysABP_count"
## [61] "NISysABP_mean"
                             "NISysABP_sd"
                                                   "PaCO2_count"
## [64] "PaCO2_mean"
                             "PaCO2_sd"
                                                   "Pa02_count"
## [67] "PaO2_mean"
                                                   "pH_count"
                             "Pa02_sd"
## [70] "pH_mean"
                             "pH sd"
                                                   "Platelets_count"
## [73] "Platelets mean"
                             "Platelets sd"
                                                   "SysABP count"
## [76] "SysABP_mean"
                             "SysABP_sd"
                                                   "Temp_count"
## [79] "Temp_mean"
                             "Temp sd"
                                                   "Urine count"
                                                   "WBC_count"
## [82] "Urine_mean"
                             "Urine_sd"
## [85] "WBC mean"
                             "WBC sd"
```

```
primera_seleccion = select(data_tidy, nombres)
View(primera_seleccion)
# DE LAS SELECCIONADAS, MIRAMOS LAS QUE TIENEN MENOS NA'S Y LAS REORDENAMOS PARA ELEGIR LAS 10 PRIMERAS
pepe = select(primera_seleccion, ends_with("sd")) %>% apply(2, contar_nas)
nombres_pocos_nas = sort(pepe)
nombres_pocos_nas
##
           HR_sd
                        Temp_sd
                                        GCS_sd Creatinine_sd
                                                                     BUN_sd
##
              61
                             62
                                            63
                                                          107
                                                                        109
##
        Urine_sd
                         HCT_sd
                                       HCO3_sd
                                               Platelets_sd
                                                                     WBC_sd
##
             121
                            128
                                           146
                                                          159
                                                                        173
##
                                                                NISysABP_sd
           Na_sd
                           K_sd
                                         Mg_sd
                                                  Glucose_sd
##
             177
                            243
                                           307
                                                          320
                                                                        642
    NIDiasABP_sd
                                   DiasABP_sd
                                                   SysABP_sd
##
                       NIMAP_sd
                                                                     MAP_sd
##
             645
                            649
                                          1216
                                                         1216
                                                                        1225
##
                                       Pa02_sd
           pH_sd
                       PaCO2_sd
                                                     Fi02_sd
                                                                MechVent_sd
##
            1276
                           1292
                                          1295
                                                         1353
                                                                        1490
nombres_def = nombres_pocos_nas[1:10]
nombres def
##
           HR_sd
                        Temp_sd
                                        GCS_sd Creatinine_sd
                                                                     BUN_sd
##
              61
                             62
                                            63
                                                          107
                                                                        109
##
        Urine sd
                         HCT sd
                                       HCO3 sd Platelets sd
                                                                     WBC sd
##
             121
                            128
                                           146
                                                          159
                                                                        173
# SOLUCION CUTRE
data_real_tidy = select(data_tidy, contains("RecordID"), contains("Age"), contains("Gender"),
                                                                                                     contai
drop_na(data_real_tidy)
## # A tibble: 3,676 x 40
                  Age Gender Height Weight ICUType `SAPS-I`
                                                               SOFA
##
      RecordID
##
         <dbl> <dbl>
                       <dbl>
                              <dbl>
                                     <dbl>
                                              <dbl>
                                                        <dbl> <dbl>
##
   1
        132539
                  54
                           0
                                -1
                                       -1
                                                  4
                                                            6
                                                                  1
##
   2
        132540
                  76
                           1
                               175.
                                       76
                                                  2
                                                           16
                                                                  8
                                -1
##
    3
        132541
                  44
                           0
                                       56.7
                                                  3
                                                           21
                                                                 11
##
   4
        132543
                  68
                               180.
                                       84.6
                                                  3
                                                            7
                                                                  1
                           1
                                                  3
                                                                  2
##
   5
        132545
                  88
                           0
                                -1
                                       -1
                                                           17
                               180.
##
        132547
                                     114
   6
                  64
                           1
                                                  1
                                                           14
                                                                 11
##
    7
        132548
                  68
                           0
                               163.
                                       87
                                                  3
                                                           14
                                                                  4
                           0
                                                  3
                                                                  8
##
   8
        132551
                  78
                               163.
                                       48.4
                                                           19
##
    9
        132555
                  74
                           1
                               175.
                                       66.1
                                                  2
                                                           14
                                                                  6
        132556
                                                  3
## 10
                  64
                           0
                                -1
                                       65
                                                           15
## # ... with 3,666 more rows, and 32 more variables: Length_of_stay <dbl>,
## #
       `In-hospital_death` <dbl>, HR_count <dbl>, HR_mean <dbl>, HR_sd <dbl>,
       Temp_count <dbl>, Temp_mean <dbl>, Temp_sd <dbl>, GCS_count <dbl>,
       GCS_mean <dbl>, GCS_sd <dbl>, Creatinine_count <dbl>,
## #
```

```
## #
       Creatinine_mean <dbl>, Creatinine_sd <dbl>, BUN_count <dbl>,
## #
      BUN_mean <dbl>, BUN_sd <dbl>, Urine_count <dbl>, Urine_mean <dbl>,
## #
      Urine_sd <dbl>, HCT_count <dbl>, HCT_mean <dbl>, HCT_sd <dbl>,
      HCO3_count <dbl>, HCO3_mean <dbl>, HCO3_sd <dbl>,
## #
## #
      Platelets_count <dbl>, Platelets_mean <dbl>, Platelets_sd <dbl>,
## #
      WBC count <dbl>, WBC mean <dbl>, WBC sd <dbl>
#las que tengan mayores diferencias con las muertes de los in hospital death
#comparaciones con un t.test, per saber si ses mitjanes son iquales o no, si soln iquales FUERA
# Hacemos contraste de hipótesis para saber si deberiamos considerar las
# varianzas iquales o diferentes para el contraste de medias que haremos a continuación.
test_varianzas = function(columna){
  # hip nula : varianzas iquales
  # hip alternativa : diferentes
  x = var.test(columna[data_real_tidy$`In-hospital_death` == 0],
               columna[data_real_tidy$`In-hospital_death` == 1])
  alpha = x$p.value
  if(alpha < 0.05){
   print('Rechazamos: Las varianzas son diferentes')
   return(FALSE)
  }
  else{
   print('Aceptamos: Las varianzas son iguales')
   return(TRUE)
 }
}
# Hacemos contraste de hipótesis para saber si las medias son iquales o no.
test_medias = function(columna){
  # hip nula : medias son iquales
  # hip alternativa: se indica en alternative = c("two.sided", "less", "greater")
  x = t.test(columna[data_real_tidy$`In-hospital_death` == 0],
             columna[data_real_tidy$`In-hospital_death` == 1],
             var.equal = test_varianzas(columna)) # Aquí aplicamos la función anterior como habíamos di
  alpha = x$p.value
  if(alpha < 0.05){
   print('Rechazamos: Las medias son diferentes')
  else{
    print('Aceptamos: Las medias son iguales')
}
# SELECCIÓN 5 VARIABLES MÁS RELEVANTES PARA PREDECIR LA MUERTE
data_real_tidy$`In-hospital_death` = factor(data_real_tidy$`In-hospital_death`, labels = c("0","1"))
# LATIDO CORAZON --
data real tidy %>%
  ggplot() +
```

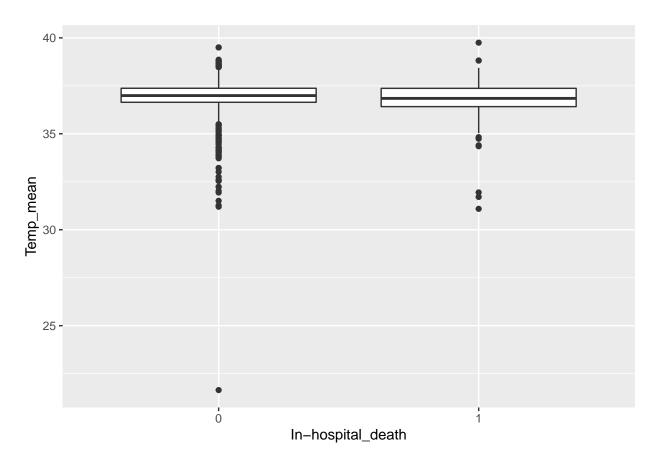
```
geom_boxplot(aes( x = `In-hospital_death`, y = HR_mean))
```

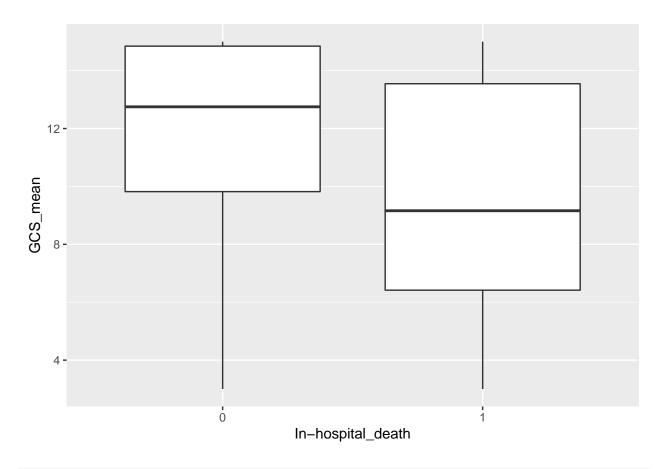


Basta hacer solo el test de medias ya que dentro de este saldra la solucion del test de varianzas. test_medias(data_real_tidy\$HR_mean)

```
## [1] "Rechazamos: Las varianzas son diferentes"
## [1] "Rechazamos: Las medias son diferentes"
```

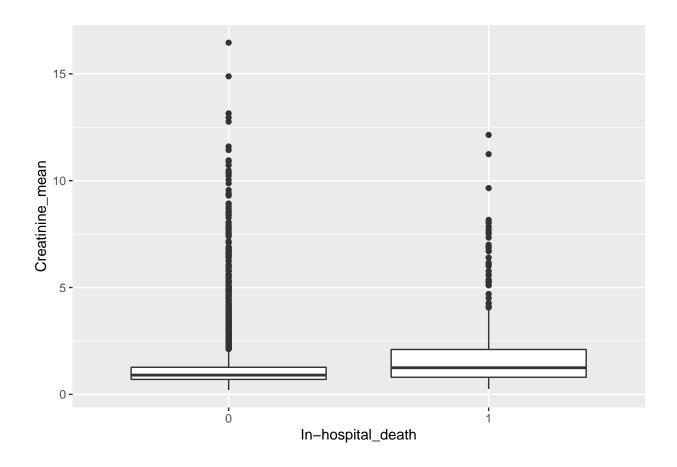
```
# TEMPERATURA ----
data_real_tidy %>%
    ggplot() +
    geom_boxplot(aes( x = `In-hospital_death`, y = Temp_mean))
```





```
## [1] "Rechazamos: Las varianzas son diferentes"
## [1] "Rechazamos: Las medias son diferentes"

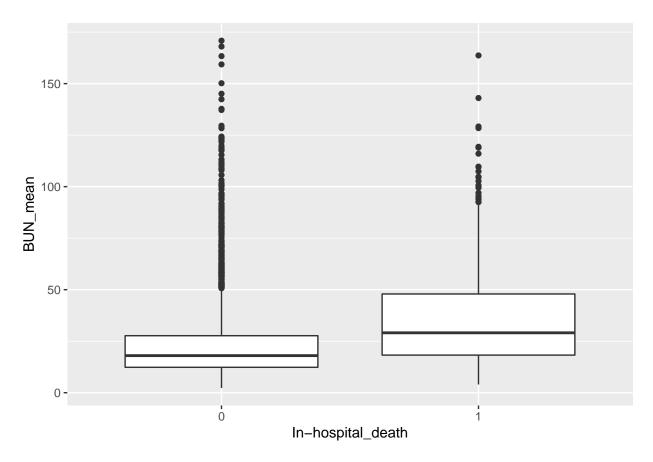
## CREATININA -----
data_real_tidy %>%
    ggplot() +
    geom_boxplot(aes( x = `In-hospital_death`, y = Creatinine_mean))
```

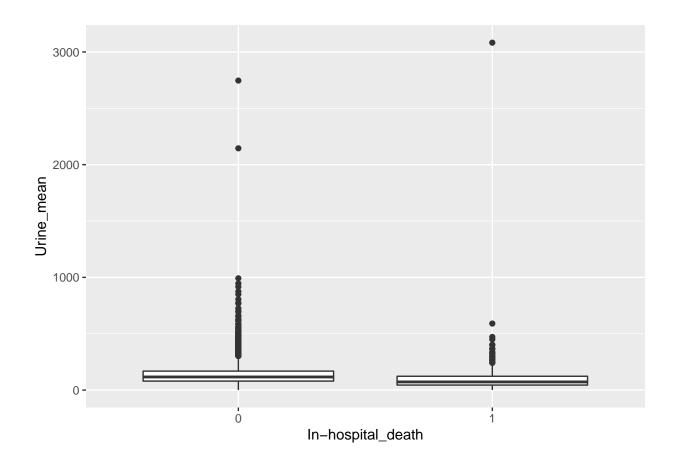


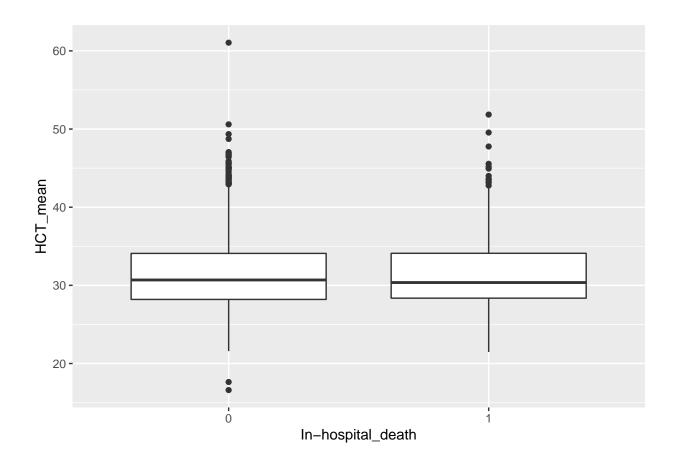
```
## [1] "Rechazamos: Las varianzas son diferentes"
## [1] "Rechazamos: Las medias son diferentes"

## NITROGENO EN SANGRE

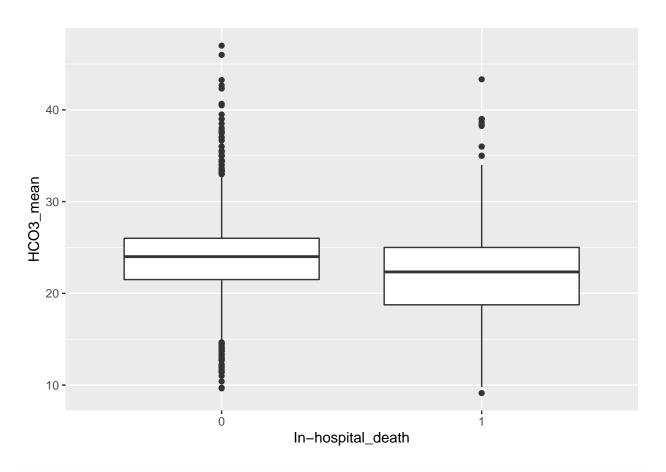
data_real_tidy %>%
    ggplot() +
    geom_boxplot(aes( x = `In-hospital_death`, y = BUN_mean))
```

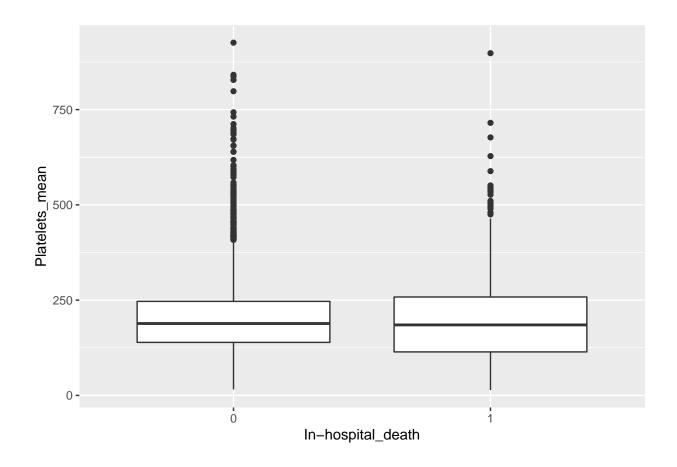




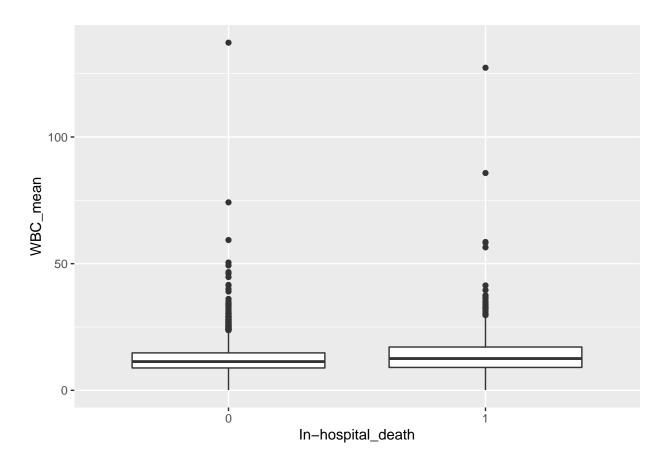


test_medias(data_real_tidy\$HCT_mean)





test_medias(data_real_tidy\$Platelets_mean)



test_medias(data_real_tidy\$WBC_mean)

```
## [1] "Rechazamos: Las varianzas son diferentes"
## [1] "Rechazamos: Las medias son diferentes"
hola= series_parameters %>% spread(Parameter, Value)
import=c()
chart.Correlation(hola[], histogram=TRUE, pch=19)
```